PokéField RAG 파이프라인 설계서

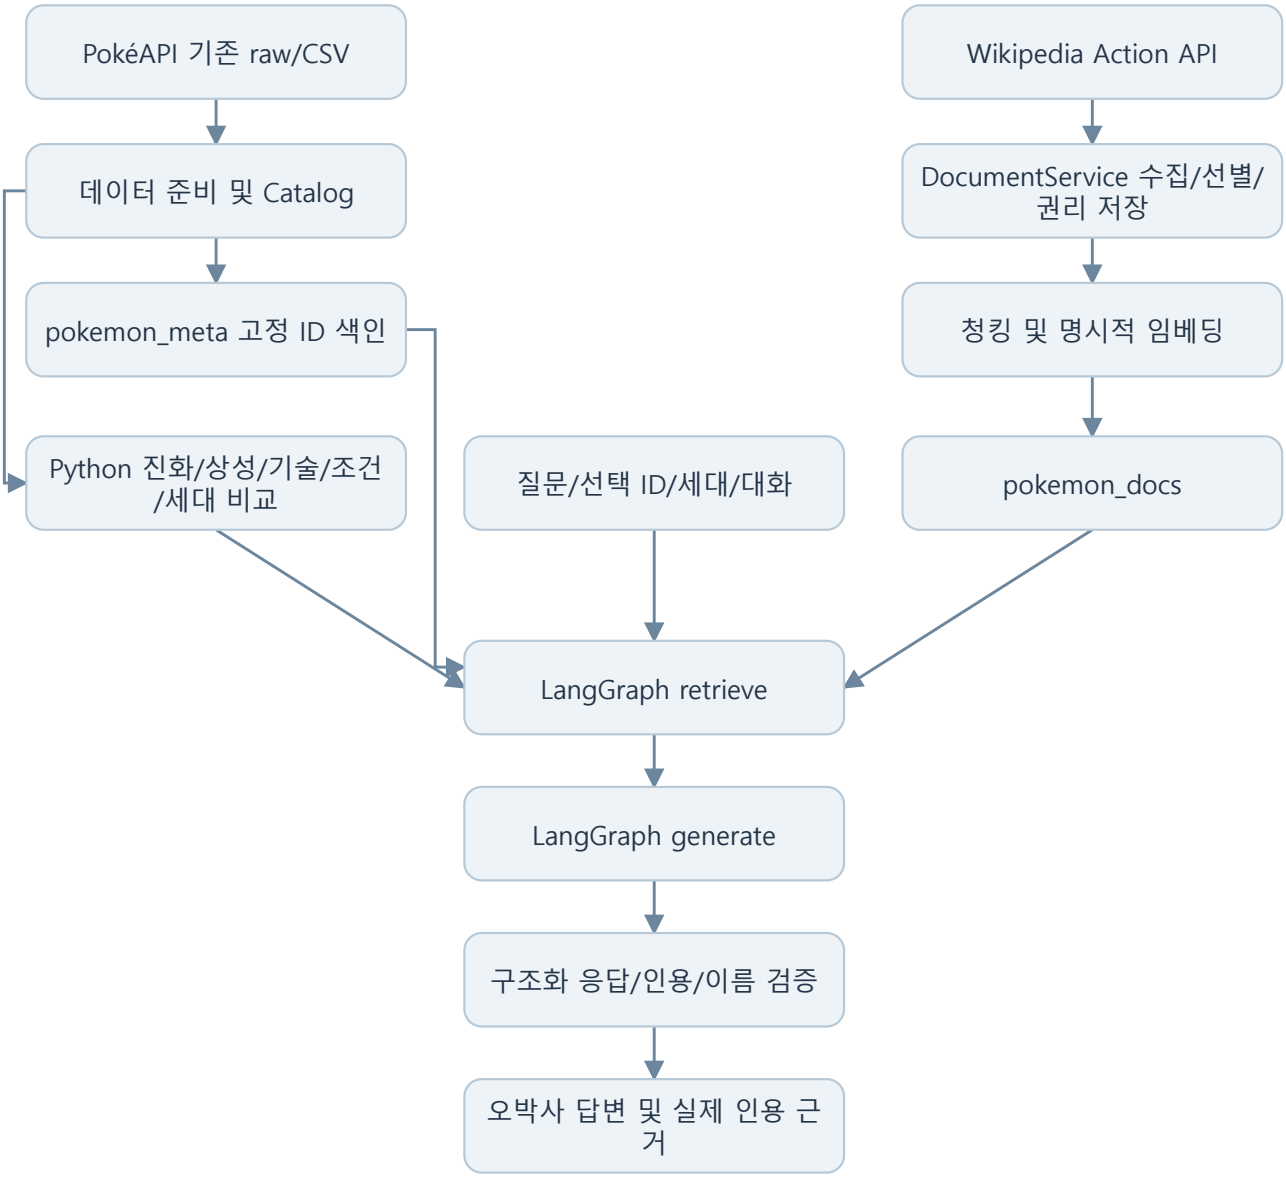
목차

1. 책임과 흐름 2
2. 두 컬렉션과 데이터 구분 3
3. 외부 문서 수집→선별→청킹→임베딩 4
4. 프롬프트와 구조화 응답 4
5. 질문 검색·병합 경로 5
6. LangGraph·생성·검증 6
7. 캐시·비용·상태 7
8. 설정과 실험 결과 7
9. 도메인 기능과 설계 이유 8

> 제출 문서 보완 기준: 2026-10-23의 기존 실행 기록과 공식 셀프 점검 결과입니다. 이번 문서 보완에서는 테스트·유료 API·재색인을 실행하지 않았습니다. 실제 GMS, 로컬 Python, 응답 캐시, 저장 응답 재생, FakeLLM/FakeEmbeddings를 구분합니다. 심화 F2013~F2016은 **미선택**입니다.

기준일: 2026-10-23. 구현 근거는 `src/·prompts/·scripts/`이며 검증 수치는 검증 요약에서 구분합니다. 실제 코드를 설명하며 아래 다이어그램의 노드를 별도 신규 파이프라인으로 구현했다는 뜻은 아닙니다.

1. 책임과 흐름



기존 Mermaid의 노드·간선을 그대로 그린 구조도입니다. 실제 실행 그래프는 아래 retrieve→generate 두 노드이며, 준비·게임 기능을 별도 LangGraph 노드로 추가하지 않았습니다.

책임	실제 모듈
데이터 수집·가공·검증	`pokemon-data/scripts/`, `scripts/build_battle_data.py`
도메인 데이터·한국어 이름·진화	`src/catalog.py`
조건 추출/정확한 후보 필터	`src/natural_search.py`
상성·기술 조회 / 세대별 차이	`src/battle.py`, `src/generation_compare.py`

책임	실제 모듈
외부 문서 수집/선별/분할	`src/document_service.py`
색인/검색/중복 제거 기반	`src/vector_store.py`
모델/임베딩/안전한 진단	`src/llm.py`
그래프/근거 구성/생성 검증	`src/rag.py`
캐시·내용 해시·측정	`src/storage.py`
Streamlit UI/필드/도감	`app.py`, `src/ui_rag.py`, `src/lab_ui.py`, `src/field/`, `src/rotom_data.py` 등

게임 이동·투척은 JavaScript, 포획 기록의 영속 저장은 `src/collection.py`의 SQLite와 Python 컴포넌트 이벤트 처리 책임입니다. RAG 그래프에 게임 루프나 별도 에이전트 그래프를 넣지 않습니다.

2. 두 컬렉션과 데이터 구분

항목	pokemon_meta	pokemon_docs
용도	포켓몬 형태·세대의 실제 역학 정보	외부 설명 문서 근거
현재 검증 건수	6,260	64청크
원천	가공 JSONL, PokéAPI 원본 이력	한국어 Wikipedia 15개 문서-종 연결/10종 범위
문서 ID	`pokemon:{pokemon_id}:gen:{generation}`	`species:{species_id}:wiki:{page_id}:{청크설정해시}:{순번}`
주요 메타데이터	species_id, pokemon_id, generation, source_url, source_type, title, content_hash	species_id, title, source_url, source_type, collected_at, license, license_url, document_key, chunk_index, content_hash, is_own_document; revision_id가 있으면 보존
source_type	pokemon_metadata	external_document
조회/필터	선택형 고정 ID get; 전체 의미 검색은 generation 필터	선택 종은 species_id 필터; 전체 의미 검색은 문서 전체 범위

Chroma 메타데이터에는 스칼라를 저장하고 타입·특성·능력치 등 배열/객체는 검색 텍스트로 직렬화합니다. `pokemon_docs` 모든 청크에 pokemon_id나 generation이 있다고 가정하지 않습니다. 문서 전체 원본과 revision_timestamp 등은 `.local/rag/documents/*.json`에 보존하며 색인에는 필요한 필드만 복사합니다.

벡터와 함께 저장한 embedding_signature가 현재 provider/base_url/model과 다르면 기존 색인을 잘못 재사용하지 않도록 오류를 냅니다. 확인된 메타데이터 벡터는 1,536차원이며 모든 모델의 차원이 고정이라는 뜻은 아닙니다. 기본 임베딩은 `text-embedding-3-small`입니다.

`pokemon_id`는 형태 단위, `species_id`는 종·진화 관계와 외부 설명 문서 연결 단위입니다. 세대별 레코드는 게임의 실제 출현 여부를 증명하지 않습니다. `game_presence=null` 및 자료 부재는 미확인으로 남깁니다.

3. 외부 문서 수집→선별→청킹→임베딩

1. `collect(species_id, question)`는 `collection:` + digest([species_id, question.strip()])로 저장 수집 결과를 찾습니다. refresh가 아니면 캐시 manifest를 `index_saved`에 전달합니다.
2. 새 HTTP가 필요할 때만 `request()`가 연락처를 확인합니다. `WIKI_CONTACT` 미설정/잘못된 헤더 문자는 요청 전 안내합니다. HTTP 응답 캐시는 연락처 확인보다 먼저 반환합니다.
3. `siteinfo/rightsinfo`에서 실제 라이선스 문구·URL을 확인합니다. 추측한 라이선스를 덮어쓰지 않습니다.
4. 검색어 추출 LLM으로 QueryPlan을 받습니다. 코드에서 종 이름을 앞에 추가하고 중복 제거 후 최대 4개 검색어를 사용합니다. 프롬프트는 추가 검색어 최대 2개를 요청하며 Pydantic 스키마 상한은 3개입니다.
5. 각 검색어에 `list=search`, srlimit=4를 사용하고 pageid로 후보를 모읍니다. `info|pageprops`로 자체 이름/이름 (포켓몬) 문서를 별도 확인하며 동음이의어·없는 문서는 제외합니다.
6. 후보 제목·요약에서 LLM이 selected_ids를 고릅니다. 후보에 실제 존재하는 ID만 허용하고 확인한 자체 문서 ID를 합칩니다. LLM 선별 결과만 믿지 않습니다.
7. `extracts|info|revisions`로 본문·원문 URL·리비전을 받습니다. 종 관련성을 검사한 뒤 원문·권리·수집 시점을 저장합니다. 없는 자체 문서를 만들거나 무관한 문서로 대체하지 않습니다.
8. `RecursiveCharacterTextSplitter(chunk_size, chunk_overlap)`로 본문을 분할합니다. 명시적 임베딩을 사용하고 요청은 최대 32개 텍스트씩 처리합니다. 임베딩 키는 signature+본문 해시입니다.
9. 동일 ID와 content_hash면 upsert를 건너뜁니다. 문서 청크 교체는 새 청크 색인 후 이전 document_key의 낡은 ID를 정리합니다. 임베딩 실패 전에 기존 문서를 먼저 삭제하지 않습니다.

Wikipedia 요청은 기본 6.2초 간격·최대 3회 시도, 429/503·Retry-After·maxlag를 처리합니다. 긴 서버 대기(30초 초과)는 빠른 재시도로 무시하지 않습니다. 실제 정책과 연락처 상태는 출처 문서를 따릅니다.

4. 프롬프트와 구조화 응답

실행에 사용하는 원본 파일은 버전 관리하되 사용자 채팅 화면에 전문을 노출하지 않습니다. 이 문서는 설계 목적·입출력을 설명하며 프롬프트를 수정하지 않습니다.

파일/지시	입력·출력	핵심 제약
`prompts/extract_query.txt`	이름·질문 → QueryPlan.queries	종 자체 이름과 세대 보존, 불필요한 검색어 억제, 입력 지시 불신

파일/지시	입력·출력	핵심 제약
`prompts/select_documents.txt`	후보 id/title/snippet → Selection.selected_ids	관련 문서만, 자체 문서 포함, 목록 밖 ID 금지, 동음이의어 제외
`prompts/generate_answer.txt`	질문·선택 형태·세대·대화 문맥·번호 붙인 evidence → Answer.claims/not_found	오박사 말투, 질문 관련 정보, 한국어 명칭, 실제 근거 번호, JSON 진화 방향/버전 조건, 모르는 이유 추측 금지
`prompts/extract_filters.txt`	질문·세대·타입 목록·로컬 특성 인식 → Filters	최소 수치/상대 조건 분리, 특성 범위, 미지원 조건 명시
`prompts/select_candidates.txt`	실제 후보 사실·임계값·결과 제한 → Picks	알려진 후보 ID만; 결과 이름·수치는 Python 재조회
`generation_compare`의 `COMPARISON_INSTRUCTIONS`	Python 차이 + 두 세대 근거 → ComparisonAnswer	변경 주장에 두 세대 메타데이터 인용, 변경 이유는 외부 문서의 직접 인용으로 검증

Answer의 claim은 text와 citations(StrictInt 목록), not_found로 구성하며 추가 필드는 금지합니다. `LanguageModel.structured()`는 JSON 전용 응답 요청과 Pydantic 스키마 검증을 수행합니다. `prompts/answer.txt`는 존재하지만 현재 생성 경로는 `generate_answer.txt`를 읽습니다. 파일 존재를 현재 사용 중이라고 표시하지 않습니다.

5. 질문 검색·병합 경로

선택형 ask(pokemon_id, generation, question, history)

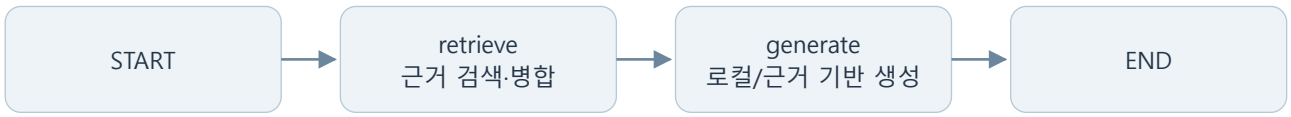
- `Catalog.index[(pid, gen)]` 존재와 `store.get_meta(pid, gen)` 색인을 확인합니다. 모든 선택 질문의 근거에 이 색인 청크를 포함합니다.
- 타입 상성/기술은 구조화 query 결과의 sources·verified_lines를 우선합니다. 기존 인용 위치가 바뀌지 않게 구조화 근거 뒤에 필수 메타데이터를 ID 중복 없이 추가합니다. 이 분기는 답변 LLM/의미 검색을 강제로 호출하지 않습니다.
- 메가를 제외한 진화 질문은 종 진화 profile을 첫 근거로 두고 색인 메타데이터를 추가합니다. 진화 JSON 근거 우선이며 외부 문서 의미 검색을 항상 거친다고 표현하지 않습니다.
- 일반/세대 비교 질문은 선택 메타데이터 및 질문에 해당하는 다른 세대 근거를 포함하고, 외부 문서를 species_id로 제한해 Top-k 의미 검색합니다. 선택적 추가 수집은 설정/체크박스에 따라 수행하며 기본 OFF다.
- 외부 근거를 합치고 species_id 및 문서 ID로 검증·중복 제거합니다. 일반 질문 메타데이터는 `answer_metadata`로 질문 관련 한국어 사실에 집중시키고, 세대 비교는 Python 비교 snapshot으로 구성합니다.

전체형 ask_global(question, history)

- 로컬 이름/다중 이름·조건·세대 인식이 우선입니다. 세대 기본값 9, 후속 질문은 지원하는 문맥 표현에서 앞선 대상을 참조합니다.
- 상성/기술은 구조화 근거, 진화는 식별한 종의 profile을 직접 조회합니다. 전체형 구조화 분기와 선택형의 필수 색인 정책을 동일하다고 기술하지 않습니다.
- 조건 검색은 `filter_rows`의 실제 JSON 후보만 사용하고, 명시적 이름이면 해당 형태/세대를 조회합니다. 이름 없는 설명형 질문은 허용된 의도일 때 기존 두 컬렉션을 의미 검색합니다. 모르는 이름을 비슷한 포켓몬으로 임의 대체하지 않습니다.
- global 의미 검색은 두 컬렉션 각각 최대 Top-k를 반환합니다. Top-k는 모든 경로의 최종 근거 총개수를 일괄 제한하는 값이 아닙니다.

공통적으로 근거 목록에 1부터 번호를 부여합니다. 대화 기록은 최근 문맥이며 근거로 취급하지 않습니다. 원문 전체 DB나 모든 포켓몬을 모델에 넘기지 않습니다.

6. LangGraph·생성·검증



`current-backend-results.json`에 기록된 실제 그래프 노드는 START, retrieve, generate, END입니다. 이 그림은 구조도이며 UI 캡처가 아닙니다.

기존 실행 그래프와 Top-k 원본 로그를 함께 제공합니다.

`build_graph`는 StateGraph(RagState)에 retrieve/generate 두 노드를 두고 `START → retrieve → generate → END`로 컴파일합니다. 전체형/선택형/세대 비교는 같은 그래프와 RagService를 재사용합니다.

`generate`에서 verified_lines가 있으면 Python이 만든 로컬 답변을 인용 범위 검사 후 반환합니다. 그 외 근거가 없으면 확인 불가 안내를 반환하고, 근거가 있으면 한 번의 구조화 답변 생성 호출을 사용합니다. 별도 말투 다듬기 LLM은 없습니다. 일반 자연어 검색의 추출/후보 선별과 선택적 문서 수집은 이 답변 생성 호출과 별도의 작업이므로 전체 요청 비용을 항상 한 번이라고 보장하지 않습니다.

검증은 (1) 구조화 스키마, (2) citations가 실제 근거 범위 안인지, (3) 본문 인용과 구조화 인용이 일치하는지, (4) 해당 인용 근거에 없는 다른 종 이름인지, (5) 세대 비교의 두 메타데이터 인용, (6) 외부 변경 이유의 원문 인용으로 구성됩니다. UI는 `cited_sources`에 따라 실제 사용 번호만 보여줍니다. 이는 의미적 함의/모든 환각을 완전히 증명하는 검사가 아닙니다.

현재 `not_found=True`와 유효한 변경 claim이 동시에 있으면 생성 후 일반적인 확인 불가 문장이 붙을 수 있습니다. 2026-10-23 팬텀 비교에서 실제로 관찰했으며 해결된 것으로 표시하지 않습니다.

7. 캐시·비용·상태

영역	실제 키/검증 방식
위키 API 응답	`wiki:` + 기본 format/maxlag 포함 params digest
수집 manifest	`collection:` + [species_id, question.strip()] digest; refresh로 재평가
LLM 선택적 캐시	provider/base_url/chat_model namespace, system/payload/json mode digest
임베딩	provider/base_url/embedding_model signature + 텍스트 digest
전체 질문 답변	payload·instructions·모델·provider digest; 진화 검증 버전 포함
세대 비교	comparison·두 meta·문서 corpus/설정·프롬프트/모델 digest
Chroma 갱신	고정 ID+content_hash, embedding_signature 일치 검사

모든 일반 선택형 답변이 응답 캐시를 사용한다고 보장하지 않습니다. 선택형 generate의 구조화 생성 호출은 cache=False다. 페이지 재실행만으로 질문/조건 제출을 새로 수행하지 않도록 UI 이벤트와 저장 메시지를 사용합니다. 말풍선은 고유 ID/reply_to와 sources를 함께 저장하고 pending만 처리합니다. 전체 기록과 pid:gen 기록이 분리됩니다.

8. 설정과 실험 결과

1000문자·중복 200문자는 문장 경계 주변 맥락을 남기면서 원문 전체 전달을 피하려는 현재 설계입니다. k=5는 관련 근거 범위를 제한하기 위한 설정입니다. 이는 설계 의도이며 다른 값보다 정확도가 높다는 실험 결과는 아닙니다. 청크 수 변화는 아래와 같이 확인했지만 응답 품질·비용의 최적값 선정 실험은 수행하지 않았습니다.

기존 청킹·Top-k·중복 방지 실행 기록을 제공합니다. 검색어는 피카츄·피카츄 진화·피카츄 세대별 특징 3개이며 후보 8개 중 61168을 선택했습니다. 선택되지 않은 후보 ID는 같은 로그의 candidate_ids와 selected_ids 차집합으로 확인합니다. rejected 필드가 비었다고 모든 후보가 선택됐다는 뜻은 아닙니다.

설정	기본/현재 확인값	의미
`CHUNK_SIZE`	1000	문자 기준 분할 길이; 토큰 수가 아님
`CHUNK_OVERLAP`	200	인접 청크 문자 중복
`TOP_K`	5	외부 검색/전체 컬렉션별 검색의 최대 후보 수
`CANDIDATE_LIMIT`	25	자연어 검색에서 모델에 보낼 제한 후보 수

설정	기본/현재 확인값	의미
`RESULT_LIMIT`	6	기본 결과 표시/관련 경로 제한
`AUTO_COLLECT_DOCUMENTS`	false	질문 시 자동 신규 수집 기본 비활성

검증된 비교는 아래와 같으며 운영 색인을 재생성한 것이 아니라 격리 DB에서 수행한 과거 실험입니다.

실험	결과	해석의 한계
동일 피카츄 저장 문서 1000/200	18청크	전체 운영 64청크와 범위가 다름
동일 문서 500/100	36청크	청크 수 증가만 검증
동일 문서 200/20	79청크	품질/비용/지연 우열은 미측정
일반 선택 질문 Top-k 1/3/5	근거 2/4/6개	필수 meta 1+외부 k개, ID 중복 없음
전체 메타데이터 재색인 2회	changed=0/skipped=6260	변경 없는 재임베딩 방지

1000/200과 k=5는 현재 설정이며 위 실험이 최적값을 입증하지는 않습니다. MMR 비교·비RAG 대비 품질 실험은 구현하지 않았습니다. 실제 지연과 토큰은 검증 요약에 기록합니다.

9. 도메인 기능과 설계 이유

- **세대 비교:** 누락과 실제 변경을 구분하고 Python으로 타입/일반·숨겨진 특성/능력치 차이를 결정합니다. 수치 계산을 모델에 맡기지 않습니다.
- **진화:** 종 ID 간 간선·조건과 순환 방지 탐색으로 직접 전/후·전체 계열·분기를 구성합니다. 세대/형태 ID를 종 ID로 오인하던 질문 실패를 피하고 profile_source의 호출 인터페이스를 재검증했습니다.
- **타입 상성:** 공격/방어·세대 규칙을 분리하고 복합 방어 배율을 곱합니다. 피카츄 땅 2배·리자몽 바위 4배·전기→땅 0배를 포함합니다. 특성/아이템/날씨 예외는 일반 상성 범위 밖임을 안내합니다.
- **기술 검색:** 한국어/영어 기술 ID와 기존 learnset·CSV를 연결합니다. 버전/방법/레벨을 보존하고 결과 페이지를 제공합니다. 없는 버전 기록으로 기술 습득 불가를 단정하지 않습니다.
- **특성 검색:** 한국어 매핑을 재사용하고 일반/숨겨진 특성·세대 변화를 실제 JSON으로 필터링합니다. 단순 조건은 LLM을 생략합니다.
- **UI 연결:** 결과 선택은 pending_pokemon에 ID/세대를 넣고 상태 추적 탭으로 실제 질문 화면을 엽니다. 단순 default 변경으로 화면이 남던 문제를 해결했습니다.
- **메타데이터 누락:** 특수 질문 조기 반환 전에 필수 색인을 확보하도록 보완했습니다. 근거 순서를 보존하여 이미 검증된 인용을 이동시키지 않습니다.

현재 운영자 연락처 공란, 이미지 권리 미확인, 외부 문서 범위 제한, 실제 단말/운영 부하 미검증은 요구사항 현황에 남깁니다.